

治理技术专题

# 定量政治分析方法

Quantitative Analysis II

苏毓淞

清华大学社会科学院政治学系

第十四讲 多层次回归



# MLM 发展背景

- 1980 年代中后期，统计学家关注到层次结构数据 (或称嵌套数据, nested data)，并提出一系列嵌套数据的统计分析方法，统称为“多层次模型” (multilevel model)。
- 多层次模型 (multilevel model) 最先应用于教育学领域，后用于心理学、社会学、政治学、经济学、组织行为与管理科学等领域，逐步应用到医学及公共卫生等领域。



# MLM 不同的名称

- 分层线性模型 (Hierarchical Linear Model)
- 多层次 (水平) 分析 (Multilevel Analysis)
- 多层次回归模型 (Multilevel regression models)
- 混合模型 (Mixed Models)
- 随机系数模型 (Random Coefficient Models)
- 方差成分模型 (Variance Component Model)



# Varying Intercept and Varying Slope models

- LSDV 模型：回归中加入集体层次 (group level) 的虚拟变量，这些虚拟变量的斜率可以当成截距解读，所以这模型又叫做 Varying Intercept 模型。

$$y_i = \alpha_{j[i]} + \beta x_i + \epsilon_i$$

- 如果只让  $\beta$  也随集体层次变动，则称为 Varying slope 模型。

$$y_i = \alpha + \beta_{j[i]} x_i + \epsilon_i$$


- 如果只  $\alpha, \beta$  都随集体层次变动，则称为 Varying-intercept Varying-slope 模型。

$$y_i = \alpha_{j[i]} + \beta_{j[i]} x_i + \epsilon_i$$




# Varying Intercept and Varying Slope models


**Varying intercepts**



**Varying slopes**



**Varying intercepts and slopes**



# 数据类型

- 面板数据 Panel data
- TSCS 数据
- 非嵌套数据 Non-nested data



# 模型选择

- LSDV
- 固定效应模型和随机效应模型
- 多层次回归 Multilevel regressions.



# 固定效应模型和随机效应模型

- Varying-intercept Varying-slope 模型有时候也被称之为随机效应模型 (或者随机系数模型), 因为集体层次的截距和斜率是从概率分布中的随机项。
- 固定效应指的是未建模的 Varying-intercepts(没有自变量估计它), 但是有时候有指的是截距不变的回归模型。
- 多层次回归模型综合了两个模型的优点, 所以请忘了固定效应模型和随机效应模型!





# 多层次回归模型

- 如果集体层次的变异量为零，则多层次回归模型等于一般回归模型。
- 如果集体层次量太少，则多层次回归模型和 LSDV 模型差异不大。
- 不过，这也说明了，总是使用多层次回归模型不会错！


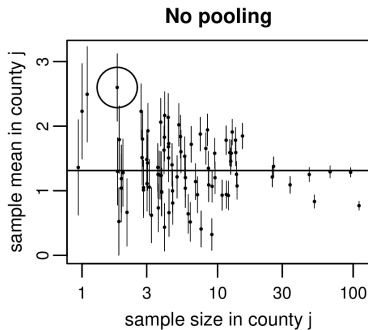


# 池化 pooling

- 如果针对集体层次量  $J$ , 进行  $J$  个回归模型, 称之为 no pooling (无池化) 分析。
- 如果针对集体层次量  $J$ , 进行 1 个回归模型, 称之为 ncomplete pooling (全池化) 分析。
- 多层次回归是以上两种的综合 (加权平均), 称之为部分池化分析 (partial pooling)



# 池化图示



## 部分池化的估计值

$$y_i = \alpha_{j[i]} + \epsilon_i$$

- 多层次回归的估计值是以上两种的综合（加权平均）。

$$\hat{\alpha}_j^{\text{多层次模型}} \approx \frac{\frac{n_j}{\sigma_y^2} \bar{y}_j + \frac{1}{\sigma_\alpha^2} \bar{y}_{\text{all}}}{\frac{n_j}{\sigma_y^2} + \frac{1}{\sigma_\alpha^2}},$$

- 如果某个集体层次的样本量小，则  $\hat{\alpha}_j$  会被拉往全池化估计值  $\bar{y}_{\text{all}}$ 。某个集体层次的样本量为零，则  $\hat{\alpha}_j = \bar{y}_{\text{all}}$
- 某个集体层次的样本量大，则  $\hat{\alpha}_j$  会被拉往无池化估计值  $\bar{y}_j$ 。某个集体层次的样本量  $\rightarrow \infty$ ，则  $\hat{\alpha}_j = \bar{y}_j$



# 无池化和全池化模型问题

- 全池化模型忽略了集体层次的变异。
- 无池化模型则容易因样本量少时出现极值。
- 部分池化（多层次回归）模型则考虑到了集体层次的变异，同时，将因样本量少产生的极值，牵引到全池化的估计值上。



# 使用 R 应用多层次回归

## ■ varying intercepts model without predictors:

```
R> M0 <- lmer(y ~ 1 + (1|group))
R> display(M0)
lmer(formula = y ~ 1 + (1 | group))
coef.est  coef.se
  -0.49     0.84

Error terms:
Groups   Name      Std.Dev.
group    (Intercept) 2.32
Residual                      4.09
---
```

number of obs: 100, groups: group, 10  
AIC = 583.6, DIC = 580.5  
deviance = 579.0



# 多层次回归数学表达式

- varying intercepts model

- 个体层次：(两种写法)

- $y_i = \alpha_{j[i]} + \beta x_i + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma_y^2)$

- $y_i \sim N(\alpha_j + \beta x_i, \sigma_y^2)$

- 集体层次 (无自变量)：(两种写法)

- $\alpha_j \sim N(\mu_a, \sigma_\alpha^2)$

- $\alpha_j = \mu_\alpha + \eta_j, \quad \eta_j \sim N(0, \sigma_\alpha^2)$

- 集体层次 (有自变量)：(两种写法)

- $\alpha_j \sim N(\gamma_0 + \gamma_1 u_j, \sigma_\alpha^2)$

- $\alpha_j = \gamma_0 + \gamma_1 u_j + \eta_j, \quad \eta_j \sim N(0, \sigma_\alpha^2)$



# 多层次回归数学表达式

- Varying intercepts and varying slopes model without group level predictors

$$y_i \sim \mathcal{N}(\alpha_{j[i]} + \beta_{j[i]}x_i, \sigma_y^2), \text{ for } i = 1, \dots, n$$
$$\begin{pmatrix} \alpha_j \\ \beta_j \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_\alpha \\ \mu_\beta \end{pmatrix}, \begin{pmatrix} \sigma_\alpha^2 & \rho\sigma_\alpha\sigma_\beta \\ \rho\sigma_\alpha\sigma_\beta & \sigma_\beta^2 \end{pmatrix}\right), \text{ for } j = 1, \dots, J,$$

- Varying intercepts and varying slopes model with group level predictors

$$\begin{pmatrix} \alpha_j \\ \beta_j \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \gamma_0^\alpha + \gamma_1^\alpha u_j \\ \gamma_0^\beta + \gamma_1^\beta u_j \end{pmatrix}, \begin{pmatrix} \sigma_\alpha^2 & \rho\sigma_\alpha\sigma_\beta \\ \rho\sigma_\alpha\sigma_\beta & \sigma_\beta^2 \end{pmatrix}\right), \text{ for } j = 1, \dots, J.$$





# 使用 R 应用多层次回归

## ■ varying intercepts model with one predictor:

```
R> M1 <- lmer(y ~ x + (1|group))
R> display(M1)
lmer(formula = y ~ x + (1 | group))
      coef.est coef.se
(Intercept) -0.71    0.83
x             2.08    0.36

Error terms:
  Groups   Name      Std.Dev.
group    (Intercept) 2.38
Residual                      3.51
---
number of obs: 100, groups: group, 10
AIC = 557.1, DIC = 551.5
deviance = 550.3
```



# 使用 R 应用多层次回归

## ■ varying intercepts model with one predictor:

```
R> M2 <- lmer(y ~ x + (1|x|group))
R> display(M2)
lmer(formula = y ~ x + (1 + x | group))
              coef.est coef.se
(Intercept) -0.75      0.80
x             2.45      0.58

Error terms:
  Groups   Name      Std.Dev. Corr
group    (Intercept) 2.30
        x           1.48    0.75
Residual                3.18
---
number of obs: 100, groups: group, 10
AIC = 549.5, DIC = 540.9
deviance = 539.2
```



# 使用 R 应用多层次回归

## ■ varying intercepts model with group level predictor:

```
> M3 <- lmer(y ~ x + u.all + (1|x|group))
> display(M3)
lmer(formula = y ~ x + u.all + (1 + x | group))
```

	coef.est	coef.se
(Intercept)	1.55	0.56
x	2.67	0.46
u.all	-0.34	0.22

Error terms:

Groups	Name	Std.Dev.	Corr
group	(Intercept)	0.08	
	x	1.11	1.00
Residual		2.75	

---

```
number of obs: 100, groups: group, 10
AIC = 507.9, DIC = 490.7
deviance = 492.3
```



# 讨论

- $J$  太少时，多层次回归模型的优势发挥不出来，无法良好的估计组间方差 ( $J$  太小)，但至少不会比 no pooling 的回归差。
- $J = 2$  时，跟传统加上虚拟变量的回归没有两样。
- 即便是每组只有 1 个样本量，也足以使用多层次回归。



# Bayesian Multilevel Modeling

$$y_i \sim N(\alpha_{j[i]} + \beta_{j[i]}, \sigma_y^2)$$
$$\begin{pmatrix} \alpha_j \\ \beta_j \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_\alpha \\ \mu_\beta \end{pmatrix}, \begin{pmatrix} \sigma_\alpha^2 & \rho\sigma_\alpha\sigma_\beta \\ \rho\sigma_\alpha\sigma_\beta & \sigma_\beta^2 \end{pmatrix}\right)$$

## ■ non-informative priors

$$\mu_\alpha \sim N(0, 1000)$$

$$\mu_\beta \sim N(0, 1000)$$

$$\sigma_y \sim U(0, 1000)$$

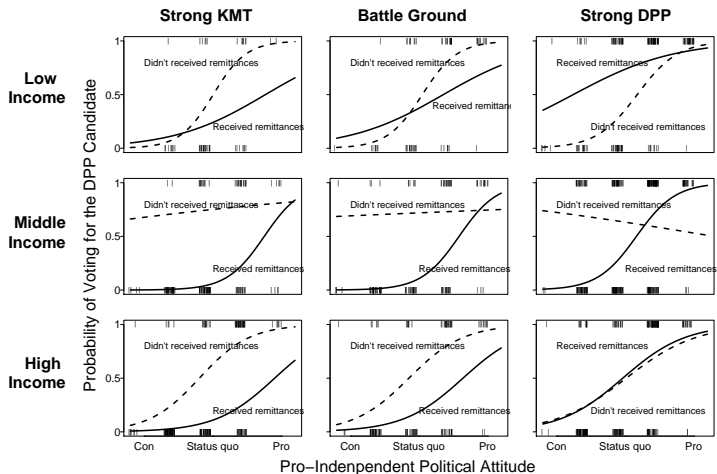
$$\sigma_\alpha \sim U(0, 1000)$$

$$\sigma_\beta \sim U(0, 1000)$$

$$\rho \sim U(-1, 1)$$



# 案例 1: Multilevel Logistic Regression



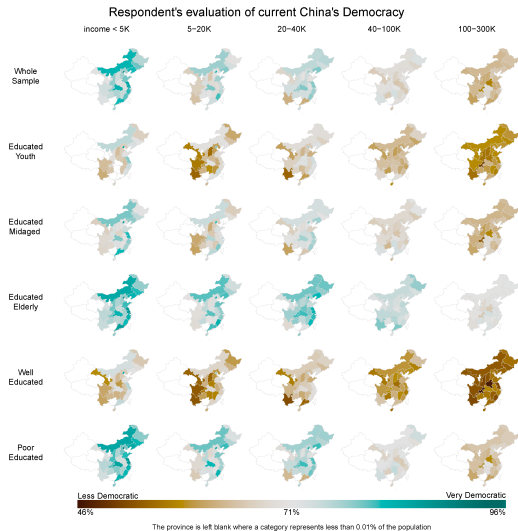
# 案例 1: Multilevel Logistic Regression

```
fit <- glmer(y ~ 1 + x1 + x2 + x1:x2 +  
(1 + x1 + x2 + x1:x2|income) +  
(1 + x1 + x2 + x1:x2|region), family=binomial(link="logit"), data=dat)
```

- y: binary variable
- x1: continuous variable
- x2: binary variable
- income: 3 levels categorical variable
- region: 3 levels categorical variable



# 案例 2: MRP





## 案例 2: MRP

```
fit <- glmer (y ~ gender*gdp +  
  (1 + gender | region) +  
  (1 + gender | province) +  
  (1 | gender.region) +  
  (1 | gender.province) +  
  (1 | gender) +  
  family=binomial(link="logit"))
```

